


## World-ETF Portfolio

datamining approach



# VERMÖGENSMANAGEMENT MIT DATASCIENCE

# Zusammenfassung

Die nachhaltig hohe Performance die SelectionAM im Trackrecord seiner Fonds nachweist basiert auf

- ▣ a) Große Erfahrung seiner Fondsmanager
- ▣ c) Konsistentes Befolgen definierter Anlagestrategien
- ▣ d) Kontinuierliches Verbessern der kritischen Erfolgsfaktoren dieser Anlagestrategien durch den Einsatz innovativer Technologie
- ▣ Neuster Coup:  
Einführung von Datascience-Technologie zur Unterstützung des Assetmanagents

# Aufgaben der Vermögensverwaltung

- Mission: Outperformance gegenüber dem Benchmarkportfolio  
Ziel: Höhrere Rendite bei geringerem Risiko
- Maßnahmen :
- 1) Überwachung täglich alle Titel monitoren und notfalls eingreifen
- 2) Assetallokation: Regelmäßige Umschichtungen im Portfolio vornehmen (1 4 täglich oder öfters)  
**Problem:** Niemand kennt die Zukunft.  
**Lösungsansatz:** - wie immer -  
„Gegenwärtiges Wissen möglichst optimal nutzen um für die Zukunft möglichst optimal positioniert zu sein.“

# Assetallokationsprozess

Outperformance durch Selektion und Assetallokation:

□ A) Nicht alle  $n$  Titel des Benchmarkportfolios kaufen sondern nur die  $k$  besten, und

B) nicht alle Titel gleichgewichten, sondern so, dass die Verluste des einen durch die Gewinne von anderen aufgefangen werden und die Portfoliorendite damit insgesamt „glatter“ wird, als die seiner Einzeltitel (geschickte Diversifikation)

# 2 Schritte in der Assetallokation

## Selektion und Allokation

### A) Selektion

Erstellung der Rankingliste

Marktdaten, Watchlist, Altes Portfolio , Social Mediadaten , News, ...

+ AnalyseTools+Erfahrung

=> Rankingliste

### B) Berechnung der Portfoliogewichte

Rankingliste und Allokationsstrategie

=> Portfoliogewichtung für den kommenden Investmentzeitraum.

Die **Qualität** dieser Schritte ist entscheidend für die **Qualität** des Portfolios

# Riskmanagement – State of the art

- Für die Diversifikation B) gibts fertige, anerkannte mathematische Risikomanagement-Werkzeuge out of the box, die den Investitionsgrad pro Titel versuchen so zu bemessen, dass sich die zeitlichen Schwankungen der Investments gegenseitig neutralisieren werden. Sie stellen u.a. sicher, dass nicht zu viele in heute schon miteinander hoch korrelierte Titel investiert wird, um so eine möglichst glatte, risikoarme Portfolio Rendite zu erzielen.
- Mathematisch gesprochen sagt man dem Rechenwerkzeug, welche wahlfreie Zielgröße man optimieren möchte (Rendite, SharpeRatio (also Rendite/Risk), Varianz,...) und das Rechenwerkzeug berechnet nach bekannten Formeln einen Satz von Portfoliogewichten (also Anteilen der Titel im Portfolio).
- Die Rechenwerkzeuge werden nach der Zielgröße benannt und heißen dann „MaxSharpe, MinVar,...“  
Diese Allokationsstrategien gehören zum Handwerkszeug vieler Vermögensverwalter.  
Die entsprechenden Softwareprogramme sind öffentlich verfügbar.
- Ganz anders ist's bei der Marktprognose:

# Marktprognose und Titelselektion

Für die Titelauswahl A) wird für jeden Titel eine Attraktivitätskennzahl berechnet und alle Titel werden nach dieser Kennzahl sortiert.

Damit erstellt ein Vermögensverwalter monatlich seine **Rankingliste** bei der seine Erwartung ist, dass die oberen Titel der Liste im nächsten Investitionszeitraum besser laufen werden als die unteren Titel der Liste.

Nun wird lediglich in die  $k$  vermutlich besten Titel investiert.

Stimmt diese Einschätzung gut genug, ist klar, dass das Portfolio nach ein paar Monaten besser laufen wird als sein Benchmarkportfolio welches ja in alle  $n$ , also auch die schlecht performenden Titel investiert ist.

Problem:

Wie findet man die benötigten Attraktivitätskennzahlen (z.B. Kursprognosen oder Overbought –Zahlen) in ausreichender Qualität ?

# Beispiel Wandelanleihenfonds

- {Claus , Wandelanleihen Methodik .. Ganz kurz ....}  
Erstellung der Rankingliste:  
Fair Value + fundamentale Aktienbewertung =>  
Unterbewertungskennzahl  
Und diese Unterbewertungskennzahl ist die  
Attraktivitätskennzahl nach der die Titel sortiert  
werden.  
Dann wird lediglich in die k attraktivsten Titel  
investiert.



# Wunsch und Wirklichkeit

Mit einer Kristallkugel:

Man braucht Wissen über die Zukunft und hat seherische Fähigkeiten.

Qualität: liegt immer richtig.

Mit einer Kristallkugel wäre Assetmanagement easy:

„Einfach immer nur den besten Titel kaufen ...“

Realität:

Es gibt keine Kristallkugel.

**Die Qualität der Attraktivitäts-Einschätzungen schwankt sehr stark.**

Manchmal liegt man richtig, manchmal liegt man falsch.

Das ist unvermeidbar.

**Gute Vermögensverwalter unterscheiden sich von Schlechten in der Qualität Ihres „educated guess“.**

Jede noch so kleine, systematische Steigerung in der Qualität der Selektionskriterien führt zu einer deutlichen Steigerung der Chance, dass die Anlagestrategie eine nachhaltige Outperformance erzielt.

{ Ergebnis Claus Wandelanleihen ...: Year2Date 3.7%, SharpeRatio: ... }

# Anlagestrategie Optimierung

- Entscheidend ist es, kontinuierlich an der Verbesserung der Selektionsqualität zu arbeiten.
- Problem:
- Für die Verbesserung der Marktpronosen können Vermögensverwalter auf 1000 Ende von Marktdaten via Bloomberg/Reuters zurückgreifen.  
Es ist aber überhaupt nicht immer klar welche dieser Daten ihnen wie bei der Attraktivitätsberechnung helfen.
- Noch schlimmer: Die Zusammenhänge an den Märkten unterliegen einem kontinuierlichen Wandel:
- Anlagestrategien die jahrelang funktioniert haben klappen heute nicht mehr.


# Kritische Erfolgsfaktoren

- Wichtig für einen Kunden ist, dass der Vermögensverwalter seine Anlagestrategie konsistent verfolgt.
- Selektionsstrategie (A) und Riskmanagement (B) müssen von hoher Qualität sein.
- Aber:  
Keine Anlagestrategie funktioniert auf Dauer unverändert.
- Das Befolgen einer Strategie allein genügt noch nicht. Entscheidend ist, dass es zusätzlich einen kontinuierlichen Verbesserungsprozess gibt der aus Marktveränderungen lernt.

# Datascience und Marktdatenanalyse

- Novum: Am Markt treten neuartige ComputerSysteme auf, die gelernt haben riesige Datenmengen (big data) zu analysieren, zu filtern (data mining) und aus diesen zu selbstständig zu lernen (machine learning).
- Beispiele: Google-Go und Translate, Auswertung von facebook->likes für Wahlkampf....

# Was ist „Datamining, BigData“ ?



- A) viele Daten sammeln
- B) und sie auch **auswerten können**

- Neue Modell- und Mustererkennungsalgorithmen ermöglichen das

Aufspüren von inneren Zusammenhängen in die man ohne clevere Algorithmen gar nicht sieht


- NEU: Die Qualität dieser Systeme erlebt gerade eine Quantensprung => Digitalisierung.



# Datascience bei SelectionAM

- Wir entwickeln unsere machine learning systeme um die Qualität unserer jahrelang schon benutzten Analysetools kontinuierlich weiter zu steigern.
- Zwei Anwendungen:
- **1) Machine Learning und menschliche Erfahrung verbinden**
- In die Berechnung unserer Attraktivitätskennzahl fließen nun auch Ergebnisse ein, die von unserem machine learning system durch die Analyse von 1000 enden markt-, news- und social-Mediadaten berechnet werden. Wir werden hier durch den langjährigen Datascience Experten Dr. Miksa seit Anfang des Jahres unterstützt. Die machine learning system ergänzt unsere eigenen Selektionskriterien.
- Vorteil: Wir optimieren unsere, in 20 jähriger Markterfahrung entwickelten Analysewerkzeuge um Kennzahlen die aus einer viel umfangreicheren Informationsanalyse stammen als noch vor wenigen Jahren vorstellbar war. Und die dahinter liegenden Analysemodell passen sich kontinuierlich dem Marktgeschehen an.

# „BigData“ – Boom im Finanzbereich



A search for Big Data reveals the sharp growth in searches from 2011 onwards:

MaryAnn Liebert, Inc. publishers  
AN E-BOOK SERIES  
Publishers of Big Data

**BIG DATA**


THE TRADING SHOW  
NEW YORK

October 1, 2014  
Three Sixty, Tribeca, NYC

New York's leading quant,  
automated trading and big data event

QUANT WORLD    AUTOMATED TRADING    BIG DATA IN FINANCE

home    sponsor    attend    about    community



Using CART for Stock  
Market Forecasting

February 28, 2014

R/Finance 2014: Applied Finance with R  
May 16 & 17, Chicago, IL, USA

**UIC** **ICFD**  
**REVOLUTION**  
ANALYTICS  
**W** **APPLIED MATHEMATICS**  
UNIVERSITY of WASHINGTON  
Computational Finance & Risk Management

**BIG DATA IN FINANCE**

THE TRADING SHOW


# Vollautomatische Assetmanagementsysteme

- II) Mit Hilfe der neuen machine learning Systeme realisieren wir darüber hinaus mehrere **vollautomatische Anlagestrategien.**
- Bisher zwei Systeme:
- 1) Long/Short seit 1.2. im Live-Einsatz ... Siehe Clueda
- 2) Vollautomatisiertes, internationales Aktien-ETF-System, Dr.Miksa (Folgeseiten)



# Was ist der ETF-Portfolio Ansatz ?

- Ökonomische Markteinschätzungen verbinden mit
- Quantitativen Analysen und Riskoptimierern
- in einem integrierten, quantitativen Softwaresystem
- zu einem systematischen Anlageprozess



# Der Ansatz Ansatz ?

- Internationales ETF-Portfolio
- Systematisches Risikomanagement (maxSharpe)
- Integration der gesamten Prozesskette:  
Timing, Selektion und Assetallokation  
bis hin zur Ordergenerierung

# Mission

Unser Ziel: Nachhaltiger, attraktiver Return

- Rendite: Ein jährlicher Return von 7 % (5% nach Kosten)
- Risk: Eine Begrenzung des Maximalverlustes auf maximal 7% (maxDrawDown)

Womit : **Weltweite** Chancen nutzen mit internationalen Index – ETFs

Benchmark:

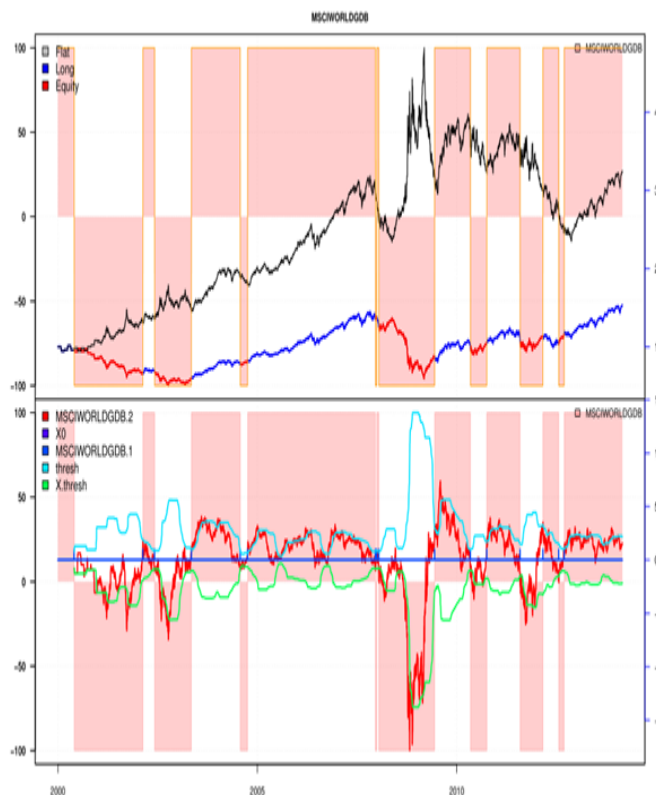
Ein gleichgewichtetes BuyAndHold Portfolio internationaler ETFs kaufen. (das kann jeder Laie)

Longlist: n über 20 Titel



# Ensemble von Tradingsystemen

SUP500  
 MSCIEUROPE  
 MSCIEMERGINGM  
 TOPIXMSCIJAPAN  
 PHYSICALGOLD  
 IGBONDS  
 HYBONDS  
 TIPS  
 REXP  
 EUROTREASURIES  
 EMTREASURIES  
 DBCURRENCIES  
 MSCIWORLDGDB  
 MSCIEUROPEGDB  
 BARCLAYS



Long Short  
Flat  
Signale

Ranking

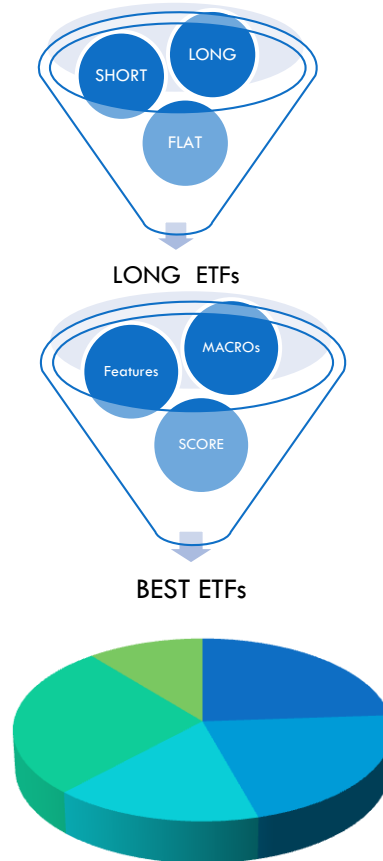
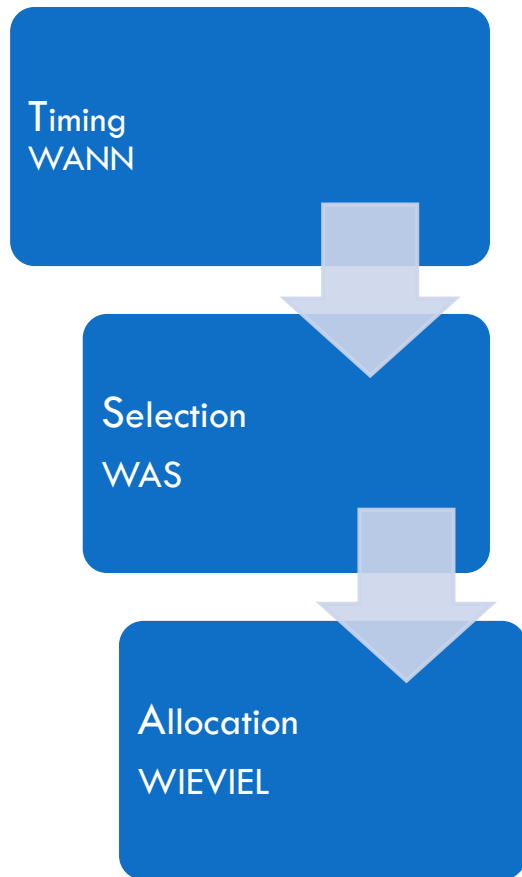
Selektion  
+ Assetallocation



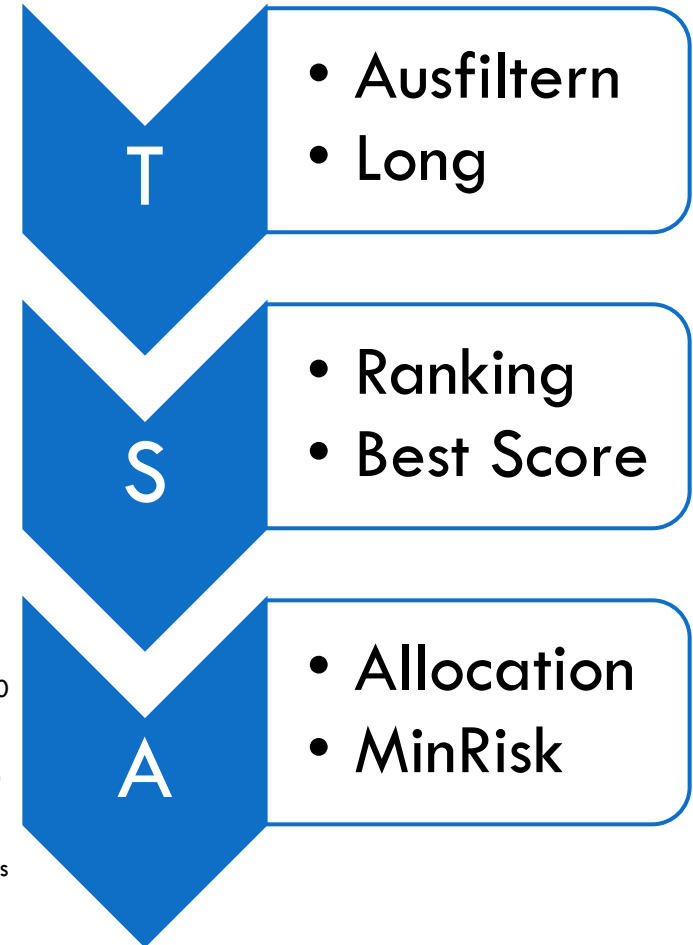
■ Stoxx50  
 ■ Nikkei  
 ■ SuP500  
 ■ Gold  
 ■ Barclays

Wenn man der TSA pro Wertpapier sagen kann, ob dieses Long/Short/Flat ist – und wie attraktiv seine Zukunft im Vergleich zu den anderen Wertpapieren beurteilt wird – kann die TSA daraus ein optimales Portfolio bauen

# Systematischer Anlageprozess



■ Stoxx50  
■ Nikkei  
■ SuP500  
■ Gold  
■ Barclays



TSA – System

# Signalverarbeitung

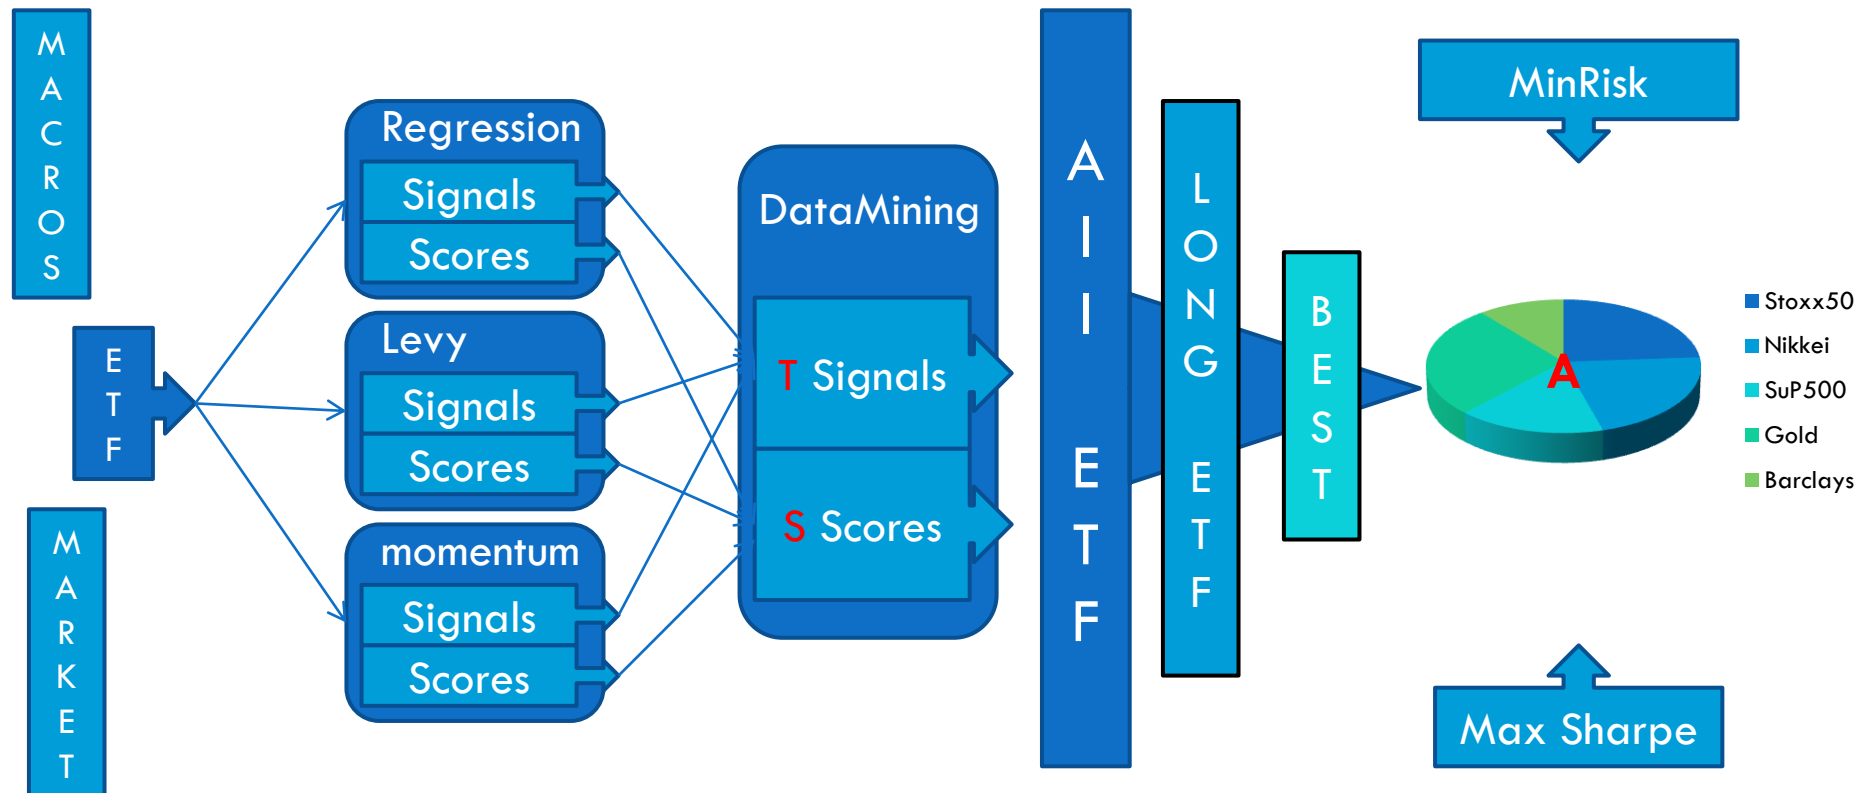
Marketdata


Multiple  
Trading Systems

DataCloud

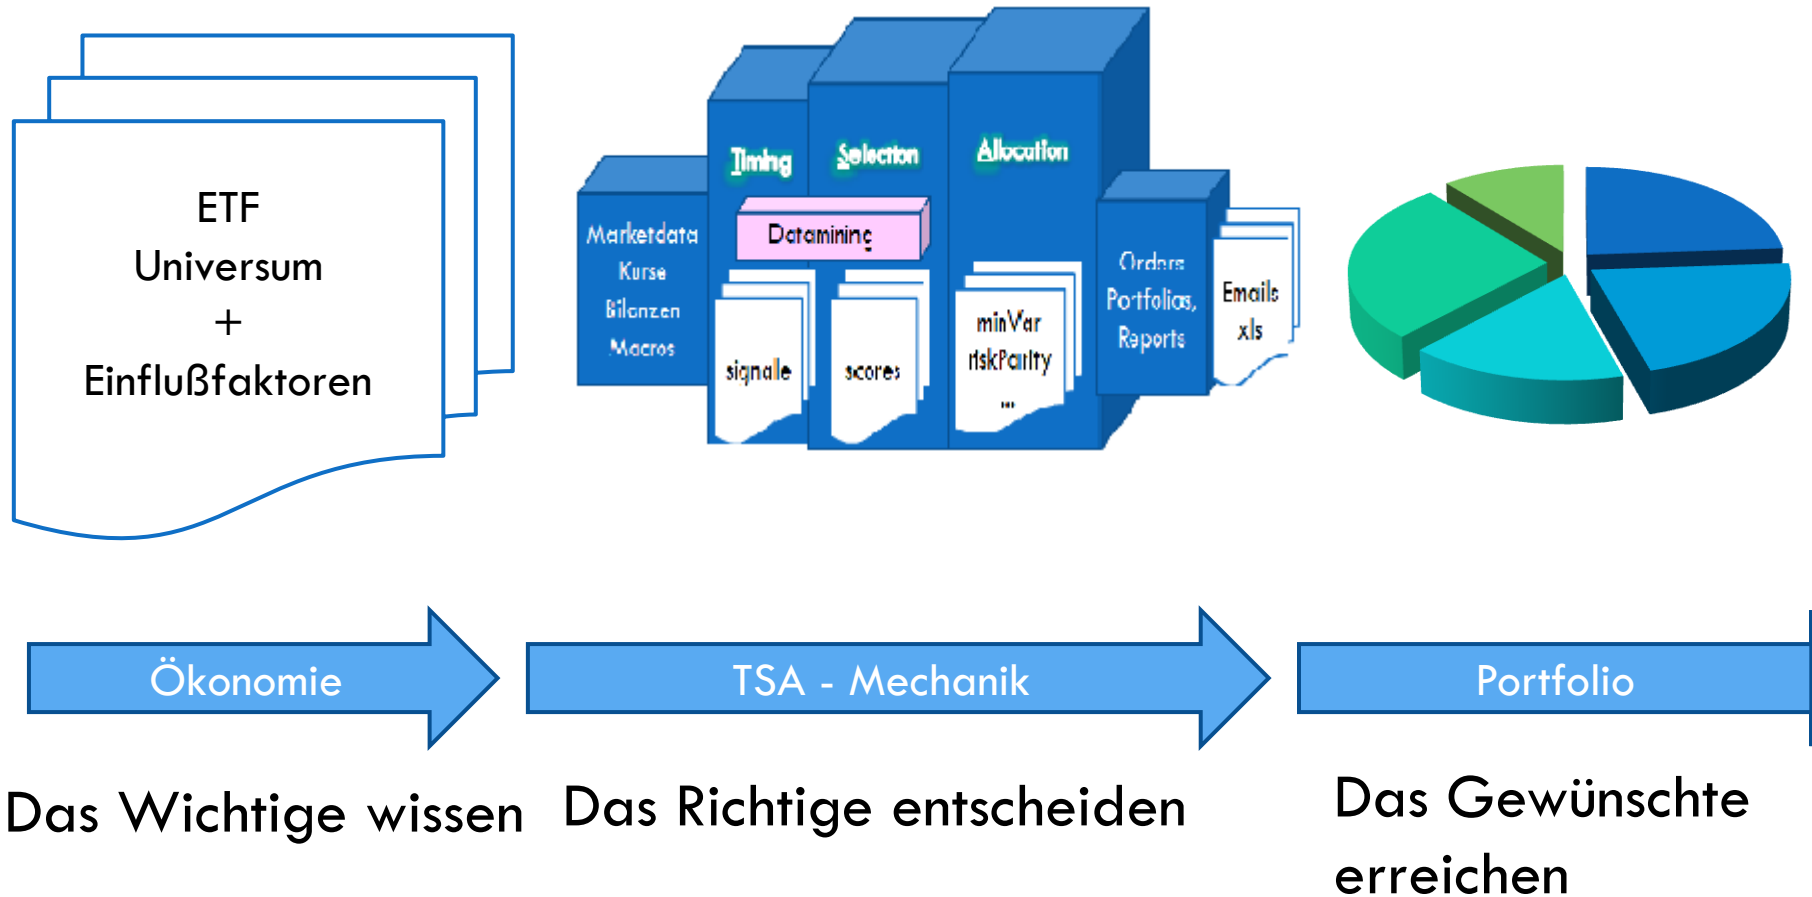
NTopK Filter

Assetallocation





# Quantitativer Anlageprozess



# Was produziert die Software ?

Kontinuierliches Abwägen der  
Marktchancen und Risiken

systematische Umsetzung in Portfolioanpassungen


- ▣ TimingSignale, Attraktivitätsrankings
- ▣ Orders zur Anpassung der Portfolios



# Ergebnisse aus unseren Backtests

- In tausenden von Backtests haben wir den Performanceeinfluß unterschiedlicher Riskmanagementmethoden und Parameter studiert:
- Erfahrungswerte:
  - Monatliche Reallocation ist stabiler wie eine Wöchentliche Reallocation
  - **MinVar** oder **MinCorrelation**, produzieren besonders glatte Equities,
  - RiskParity, Clustered RiskParity, ... Haben oft geringeren TurnOver ...
  - **MaxSharpe** produzieren meist einen höheren Return – bei höherer Volatilität (EquityKurve wird steiler, schwankt aber mehr)
- Für Fundamentalfaktormodelle genügt eine einfache lineare Regression nicht. Hier lohnen moderne multivariate Verfahren (datamining)
- Modelle dürfen nur sehr wenige Stellgrößen haben (sonst droht overfitting)
- TimingModelle allein, sind viel zu instabil !
- Am Besten funktioniert ein **Ensemble unterschiedlichster Modellstrategien** (Diversifikation auf der Ebene der Modellalgorithmen)

# Welche Performance schaffen wir ?




System	EW.S.usr.A	MV.S.usr.A	MC.S.usr.A	C.RP.S.usr.A	TRET.12.S.usr.A	MS.S.usr.A
Period	Dez1999 – Feb2014	Dez1999 – Feb2014	Dez1999 – Feb2014	Dez1999 – Feb2014	Dez1999 – Feb2014	Dez1999 – Feb2014
Cagr	8.79	6.56	7.49	8.03	8.17	9.05
Sharpe	1.02	2.01	1.71	1.79	1.13	1.29
DVR	0.99	1.98	1.7	1.77	1.07	1.27
Volatility	5.87	2.2	2.94	3	4.91	4.7
MaxDD	-14.52	-5.86	-6.76	-7.82	-19.14	-16.86
AvgDD	-0.97	-0.33	-0.43	-0.45	-0.81	-0.63
VaR	-0.5	-0.19	-0.25	-0.26	-0.39	-0.29
CVaR	-0.96	-0.35	-0.46	-0.47	-0.78	-0.67
Exposure	94.08	94.08	94.08	94.08	94.08	94.08
Turnover	178.7	402.5	329.4	369.3	931.6	696.6

# Im Backtest: kein Verlustjahr ...


MC.S.usr.A

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec	Year	MaxDD
1999													0.0	0.0
2000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.5	1.1	1.6	-0.4
2001	1.2	-0.5	0.7	-0.5	0.7	1.2	0.1	1.2	0.1	1.6	0.1	0.3	6.2	-1.8
2002	1.0	1.1	0.5	0.9	0.8	-1.4	-1.2	1.9	0.3	0.6	1.5	2.4	8.7	-2.7
2003	2.1	1.3	-0.2	2.3	2.9	0.5	-1.2	1.9	1.8	2.5	1.3	2.1	18.8	-2.8
2004	1.7	1.3	0.4	-1.0	-1.1	1.6	0.2	1.4	0.9	1.6	2.6	1.7	11.7	-4.3
2005	0.2	1.3	-1.3	0.1	0.7	1.3	0.5	0.7	2.1	-1.4	1.2	1.4	7.0	-2.0
2006	2.2	1.1	-0.7	1.3	-2.8	-0.3	2.3	1.9	0.3	1.8	1.7	1.0	10.2	-6.8
2007	0.4	0.7	0.6	1.3	0.6	-1.1	-2.2	-0.8	2.9	3.9	-1.5	1.5	6.2	-6.3
2008	1.1	0.9	-0.6	0.4	-0.3	-1.8	1.1	0.4	-2.0	-0.2	1.9	0.5	1.2	-3.7
2009	-0.2	1.1	0.8	0.5	0.5	1.3	1.3	0.9	2.1	0.5	1.3	0.4	11.1	-1.2
2010	1.3	0.6	2.2	0.8	-1.7	0.3	0.2	2.5	0.4	0.7	-2.4	0.7	5.6	-3.4
2011	-0.5	1.4	0.1	1.9	0.3	-0.9	1.0	-1.2	-2.1	1.0	-1.7	1.9	1.1	-4.8
2012	1.7	1.5	0.0	0.4	-0.2	0.6	2.5	1.2	0.9	0.6	1.1	1.0	11.9	-1.0
2013	-0.5	0.1	0.3	2.3	-1.5	-2.8	1.9	-0.7	2.1	2.1	0.8	0.2	4.1	-6.5
2014	0.9	1.2											2.1	-0.5
Avg	0.8	0.9	0.2	0.8	-0.1	-0.1	0.5	0.8	0.7	1.1	0.6	1.2	6.7	-3.0

Average Monthly Returns

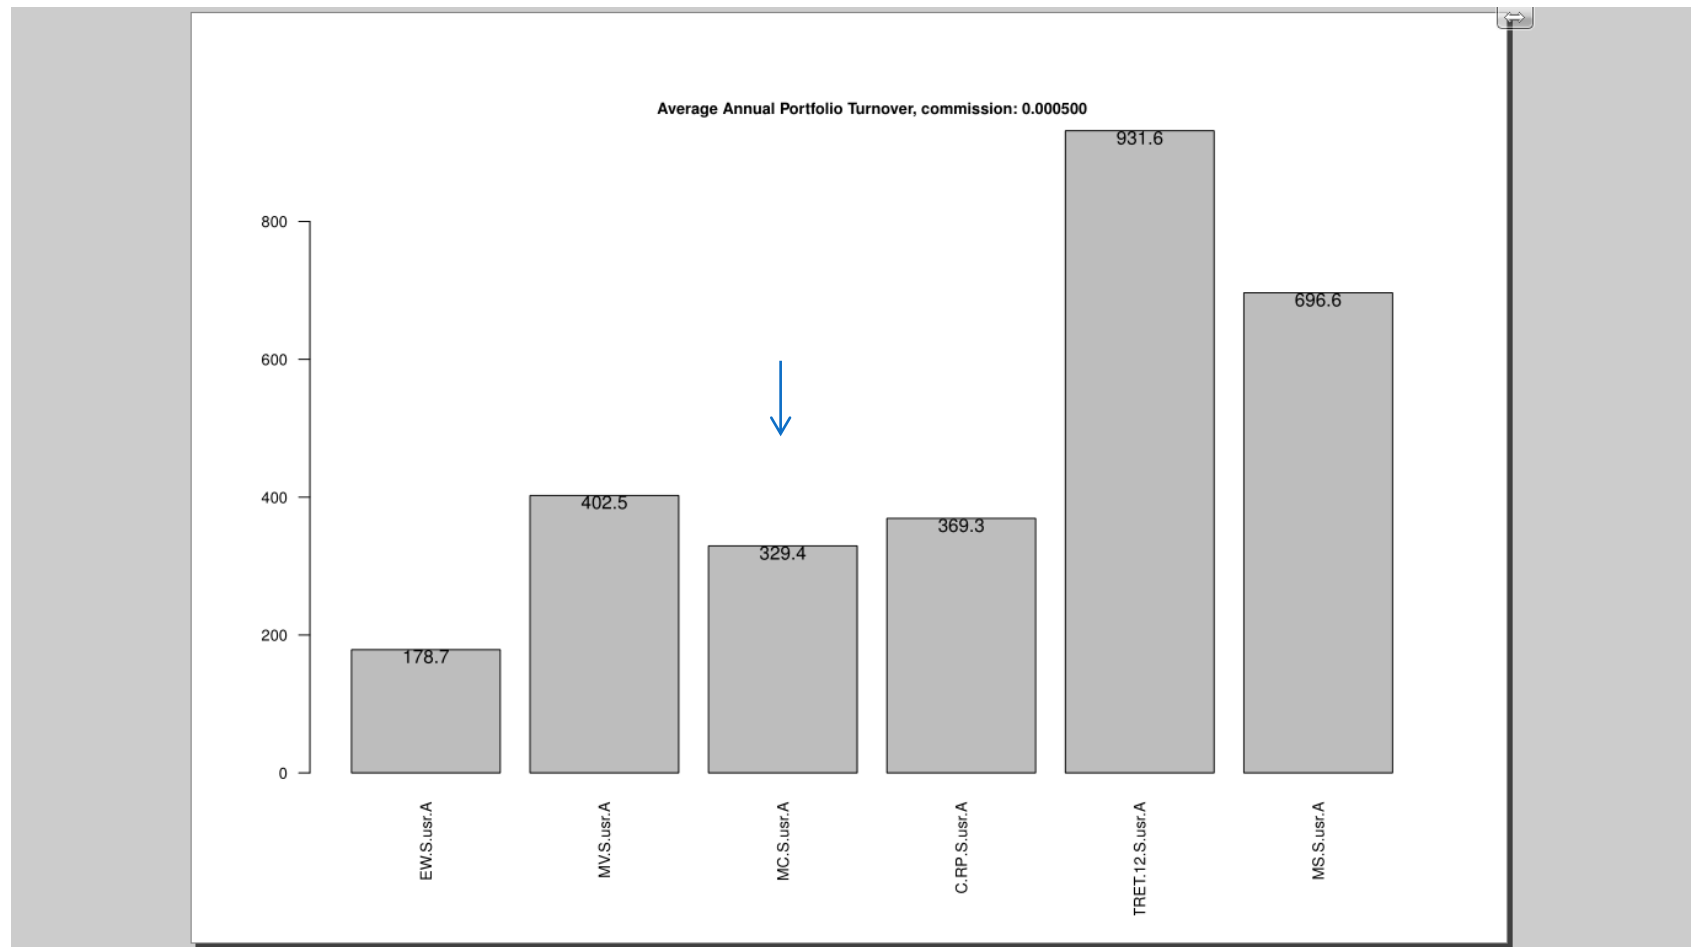


Annual Returns




# Sehr vernünftiger Turnover

( bei 5 BP per Trade )



# Stabil, auch bei Parameteränderungen



# Zusammenfassung

## Portfolio aus internationalen ETFs

- Verbindung von quantitativen Modellen und fundamentalen Macro-Daten
- Alle drei Schritte: Timing + Selektion + Allokation
- Statt Einzelmodell: Ensemble von Modellen
- Datamining findet die relevanten Zusammenhänge
- HighEnd Assetallokation-Algorithmen bauen daraus das Portfolio
- Technisch realisierbar:

5% bei maximal 7% Verlust

# Vielen Dank

